

基于低秩专家混合的多任务密集预测

Yuqi Yang^{1,2*} Peng-Tao Jiang^{2*} Qibin Hou^{1,3†} Hao Zhang² Jinwei Chen² Bo Li²

¹VCIP, CS, Nankai University ²vivo Mobile Communication Co., Ltd ³NKIARI, Shenzhen Futian

yangyq2000@mail.nankai.edu.cn, pt.jiang@vivo.com, andrewhoux@gmail.com

Abstract

基于混合专家 (MoE) 的多任务密集预测方法虽然取得了很好的性能，但它们忽视了明确建模所有任务之间全局关系的重要性。在本文中，作者提出了一种针对多任务密集预测的新型解码器焦点方法，称为低秩混合专家 (MLoRE)。为了建模任务间的全局关系，MLoRE 在原始 MoE 结构中增加了一个通用卷积路径，每个任务特征都可以通过该路径进行显式参数共享。此外，为了控制专家数量增加所带来的参数和计算成本，我们从 LoRA 获得灵感，提出利用专家网络中普通卷积的低秩格式。由于低秩专家拥有更少的参数，并且可以动态地参数化为通用卷积，因此即使专家数量增加，参数和计算成本也不会有很大变化。受益于这一设计，我们增加了专家的数量及其感受野，以扩大表示能力，从而在统一网络中促进多个密集任务的学习。在 PASCAL-Context 和 NYUD-v2 基准上的大量实验表明，我们的 MLoRE 在所有指标上均优于先前的最先进方法。我们的代码可以在<https://github.com/YuqiYang213/MLoRE> 获取。

1. Introduction

计算机视觉任务，如语义分割 [5, 29, 32, 51] 和深度估计 [2, 37]，已通过深度学习技术得到了显著的推动。每个视觉任务都有自己精心设计的深度模型，这些模型通常遵循相似的流程，例如特征提取和预测。此外，一些任务之间也存在关联。这些事实促使研究人员研

*The first two authors contributed equally to this paper. Work was done when Yuqi Yang was an intern at vivo.

†Qibin Hou is the corresponding author.




图 1. 与最先进方法的性能比较。我们基于提出的低秩专家混合模型 MLoRE 在所有任务上都取得了优异的表现。↑ 表示数值越高越好。↓ 表示数值越低越好。

究多任务学习 (MTL)，该方法能够将不同的任务模型统一到一个模型中。多任务学习的显著优势在于，它可以在保持各任务模型性能相当的同时，提升训练和推理效率。由于这一优势，多任务学习模型已被应用于多个方向，包括自动驾驶 [23, 28, 52] 和场景理解 [46, 48] 等等。

本文中，我们专注于密集场景理解中的多任务学习，每个任务都预测像素级结果。早期工作的一条研究路线 [4, 16, 33, 35, 45, 46, 48] 侧重于设计精细的网络架构，包括以编码器为主的方法和以解码器为主的方法。编码器为主的方法 [16, 33, 35] 设计手工制作的模块以在特定任务的编码器之间共享，构建任务通用特征，而解码器为主的方法 [4, 45, 46, 48] 则提出了定制解码器，以学习可区分的任务专用表示，并构建跨任务关系。

表 1. 标准 MoE 和 MLoRE 在不同设置下的参数和 FLOPs。左侧设置展示了专家数量和专家网络中卷积核大小。

设置	参数 (M)		FLOPs (G)	
	MoE	MLoRE	MoE	MLoRE
5 experts, [1×1, 1×1]	3.1	1.2	3.00	1.49
10 experts, [1×1, 1×1]	4.7	1.6	4.49	1.58
15 experts, [1×1, 1×1]	6.3	1.9	5.99	1.66
5 experts, [3×3, 1×1]	14.9	3.4	14.24	7.12
10 experts, [3×3, 1×1]	22.4	4.7	21.37	7.21
15 experts, [3×3, 1×1]	29.9	6.0	28.49	7.29

与上述专注于设计静态网络架构的方法不同，一些方法 [6, 10, 14] 引入了混合专家 (MoE) 技术，提供了一种任务专门化和协作的动态自动学习方式 [10]。它们利用 MoE 设计编码器模块，并为不同任务和样本动态选择网络路径。然而，与这些编码器为主的方法相比，MoE 在解码器中的应用研究较少，直到最近 Ye 等人 *et al.* [50] 首次将 MoE 应用于解码器。该方法通过动态组合来自不同专家的任务通用特征，解码任务专用特征，并在性能上优于以前的解码器为主的方法。这激励我们深入研究基于 MoE 的多任务学习解码器。

得益于动态路由过程，这些基于 MoE 的方法可以显著提高参数和特征的多样性，从而产生更具区分性的任务专用特征。然而，这种模式仍然存在一些局限性。首先，虽然基于 MoE 的方法可以通过在动态路由过程中共享相同专家来在部分任务中建立连接，但在所有任务之间共享专家的机会非常低，这可能会阻碍路由器在所有任务之间建立全局关系。然而，全局关系建模在 [48, 49] 中已被证明对密集型多任务学习有用。基于此事实，我们认为在 MoE 中明确建模所有任务之间的全局关系是至关重要的。此外，任务通用特征空间的容量与专家数量密切相关。如 [11, 15] 中实验证明，增加专家数量有助于在统一网络中促进多任务学习。然而，对于现有的密集型多任务学习，增加更多专家网络将引入更多参数和计算成本，这对整个模型来说是一个沉重的负担。

为了解决上述问题，我们提出了一种新的解码器为主的方法，我们称之为低秩混合专家 (MLoRE)。MLoRE 框架的核心思想是显式建模 MoE 中所有任务之间的全局关系，并在增加专家数量以扩大任务通用特征空间和上下文时，减轻 MoE 的密集计算负担。为了

解决第一个问题，MLoRE 基于基本的 MoE 结构，引入了一个与 MoE 并行的任务共享通用卷积路径。具体来说，首先将 Backbone 特征投射到不同的任务特征，然后将它们全部输入到通用卷积路径和原始 MoE 的专家网络中。通过简单地在所有任务中共享相同的通用路径，不同任务可以全局关联。此外，为了增强任务专用特征的区分性，我们将一些专家排除在动态路由过程之外，使其服务于特定任务。

为了在不引入过多参数和 FLOPs 的情况下增加专家的数量，我们从 LoRA 中获得灵感，认为适应不同任务的基本模型仅需要低秩权重更新。具体来说，我们将 MoE 的专家网络转换为普通卷积的不同低秩形式，这比标准 MoE 模块节省了 60% 以上的参数，如表 Tab. 1 所示。此外，为了控制由于增加专家网络数量带来的计算成本，我们在所有专家网络和通用卷积路径中都不使用任何非线性激活函数，这使得在推理过程中可以进行重参数化。通过重参数化，专家的知识可以注入到通用卷积路径中，从而减少密集任务的计算成本。据我们所知，我们是首个在 MoE 中使用线性专家进行多任务密集预测的工作。为了验证我们方法的有效性，我们在 PASCAL-Context 和 NYUD-v2 数据集上进行了综合实验。我们的方法在所有任务上均取得了新的性能记录，如图 Fig. 1 所示。

总结起来，我们的贡献主要有三点：

- 我们分析了 MoE 在多任务学习中应用时遇到的问题，并提出了一种全新的以解码器为中心的框架 MLoRE，能够显式建模所有任务之间的全局关系，并在不显著增加模型规模的情况下扩展特征表示的能力。
- 我们引入了一个简单的任务共享通用路径到 MoE 结构中，并提出了基于 LoRA 启发的线性和低秩专家网络。通用卷积路径和低秩专家路径可以线性结合，使得在推理时能够进行重参数化。
- 在 PASCAL-Context 和 NYUDv2 上的实验表明，所提出的方法在所有任务上明显优于之前的最先进的多任务学习方法。

2. Related Work

2.1. 密集多任务学习

在计算机视觉领域, 针对密集预测任务的多任务学习 (MTL) 已经得到了广泛的研究。以往的方法可以分为两类, 包括基于优化的方法和基于架构的方法 [44]。优化方法 [8, 9, 17, 27, 55] 通过使用不同的策略平衡每个任务的影响来促进 MTL 的发展。基于架构的方法旨在设计一个统一的深层网络进行多任务学习。它们可以进一步分为两类, 即以编码器为中心的方法和以解码器为中心的方法。(i) 以编码器为中心的方法 [3, 18, 33, 38] 设计多任务 Backbone 网络来提取适应不同任务的特征。典型方法包括交叉缝合网络 [35], 神经判别维度缩减网络 [16], 多任务注意力网络 [30], 分支网络 [43], 以及专家混合网络 [10, 14]。(ii) 以解码器为中心的方法 [4, 45, 46, 48–50, 53, 54, 56] 共享相同的 Backbone 网络, 并设计精细的 Head 来提取每个任务的任务特定特征和跨任务关系。以解码器为中心的方法的优势在于它们可以从现成的强大视觉 Backbone 网络中受益, 如 DINOv2 [36]。我们的方法同样属于以解码器为中心类别, 研究如何利用 MoE 技术有效地产生任务特定特征。

2.2. 混合专家

混合专家 (MoE) [24, 25] 学习多个专家网络, 并使用一个路由网络来控制每个专家对最终输出贡献的概率。这一技术也被应用于多任务学习, 可以更好地适应数据的多样性。不同的专家网络从训练数据中学习不同的判别特征。路由网络学习到硬/软的任务特定系数, 以动态地为每个任务组合判别特征。之前基于 MoE 的多任务方法 [6, 10, 14] 主要是以编码器为中心的方法。它们将 MoE 引入到 Backbone 块中, 在推理阶段为不同的任务稀疏激活不同的路径。最近, Ye 等人 *et al.* [50] 首次将 MoE 技术引入了解码器。他们利用空间上下文感知门将来自不同专家网络的每个像素的特征进行结合。这些方法将 Backbone 特征分解为多个通用特征空间, 并从中组合出判别性的任务特定特征。与上述基于 MoE 的多任务学习方法不同, 我们的方法首次在 MoE 结构中明确构建了所有任务之间的全局关系, 而不是通过任务特定的路由器隐式完成这一工作。此外, 我们提出的低秩专家使得 MoE 在效率上优于普

通的 MoE 结构, 并且随着专家数量的增加, 这种差距逐渐扩大。

2.3. 低秩结构

低秩结构因其高效性在深度学习中被广泛使用 [22, 40, 42, 47]。近年来, 许多参数高效适应的方法 [21, 26, 31, 41], 例如 LoRA [21], 利用了低秩结构并取得了显著的成果。LoRA 的灵感来源于 Aghajanyan 等人 *et al.* [1], 即预训练模型和适应模型之间的权重差异在于低的内在秩。它学习一个额外的低秩矩阵, 而不是调整整个层来进行适应。与我们的工作更相关的是, 早期的多任务学习方法 [40, 47] 利用低秩结构来建模任务通用特征, 并通过线性组合生成任务特定特征。与这些方法不同, 我们的方法利用低秩结构来控制 MoE 中增加专家数量时的计算预算。

3. Method

3.1. 整体框架

整体框架遵循了之前工作中使用的多尺度架构 [49, 50]。我们利用了一个现成的视觉 Transformer (ViT) 作为编码器, 并从不同层级收集多尺度特征。形式上, 给定输入图像 $\mathbf{I}$ 和一个视觉 Transformer $\mathcal{F}$, 我们可以从不同层级中获得多尺度特征集 $\{\mathbf{X}^l = \mathcal{F}^l(\mathbf{I})\}$, 其中 $\mathbf{X}^l \in \mathbb{R}^{L \times C}$ 。这里, l 表示层级索引, $L = H \times W$ 表示 Patch 的数量, C 表示特征维度。 $\mathcal{F}^l(\mathbf{I})$ 是第 l 层 Transformer 的输出特征。多尺度特征被输入到解码器中, 该解码器包括每个尺度上堆叠的两个 MLoRE 模块。对于每个任务, 从不同尺度得到的 MLoRE 输出特征会被拼接在一起, 以生成最终的密集预测任务特征。

3.2. 前言: 混合专家

在详细描述所提出的低秩混合专家 (MLoRE) 模块之前, 我们首先介绍 MoE 的基本形式 $f_{moe}(\cdot)$ 。形式上, 假设 MoE 包含 N 个专家和 T 个路由网络, 分别记作 $\mathbb{E} = \{E_1, E_2, \dots, E_N\}$ 和 $\mathbb{G} = \{G_1, G_2, \dots, G_T\}$ 。 N 和 T 分别是专家的数量和任务的数量。来自第 l 层的 Backbone 特征 $\mathbf{X}^l$ 被分别输入到 N 个专家网络和 T 个路由网络中。为了方便起见, 下面的公式中省略了上标 l 。对于第 n 个专家, 判别输出特征由 $\mathbf{x}_n = E_n(\mathbf{X})$ 生成。与此同时, MoE 从任务特定的路由网络中学习门控值用于不同的任务。对于任务 t , 由路由网络生




图 2. 我们的方法的整体框架。MLoRE 模块被装配在不同的层级上，来自不同层级的主干特征分别输入到 MLoRE 模块中。在每个选定的层级上，首先将主干特征投影到不同的任务特征中，然后送入任务共享卷积、任务共享低秩专家网络，接着经过任务特定的路由网络和任务特定的低秩专家网络。这些分支的输出被累加以生成任务特定特征。在每个选定的层级上，我们堆叠了两个 MLoRE 模块。

成的每个专家的门控值可以表示为 $\mathbf{g}^t = G_t(\mathbf{X})$ ，其中 $\mathbf{g}^t \in \mathbb{R}^N$ 。最后，MoE 利用门控值结合专家特征来生成任务 t 的任务特定特征 $\mathbf{S}^t$ ，其公式为

$$\mathbf{S}^t = f_{moe}(\mathbf{X}) = \sum_{n=1}^N \mathbf{g}_n^t \mathbf{X}_n. \quad (1)$$

对于 M³ViT [14] 和 Mod-Squad [10]，它们根据相应的门控值在一次推理中关闭一些专家，并选择 top- k 专家。这些任务特定的特征用于对每个任务进行预测。

MoE 的优点在于它能够为每个样本和每个任务动态地编码特征，并通过多个专家增加特征编码的多样性。然而，在将 MoE 技术应用于构建多任务学习解码器时，我们发现它在构建全局任务关系方面存在困难。此外，当增加专家数量以扩大特征表示能力和专家网络的上下文时，参数和计算成本也会相应增加。为了解决这些问题，我们提出了低秩混合专家 (MLoRE) 模块。

3.3. 低秩混合专家 (MLoRE)

所提出的低秩混合专家 (MLoRE) 模块的整体流程如 Fig. 2 所示。考虑到在任务特定特征间构建跨任务关系，我们首先使用几个轻量级的卷积层将 Backbone 特征投射为任务特征。然后，每个任务的特征被送到任务共享的通用路径和多个任务共享的专家网络，这些专家网络具有不同的低秩卷积。低秩专家的选择是根据任务特定路由网络对每个任务的预测结果来决定的。

此外，除了基于任务特定路由器构建任务特定特征外，我们还引入了额外的任务特定低秩专家网络，以帮助构建更具判别性的任务特定特征。来自任务共享通用路径、任务共享低秩专家网络（由任务特定路由器选择）和任务特定专家网络的特征被加总在一起，以生成判别性的任务特定特征。我们在 MLoRE 模块中引入了线性化，并且在所有路径中不使用任何激活函数，从而实现重参数化以减少计算成本。

具体来说，第 l 层的 Backbone 特征 $\mathbf{X}$ 首先通过 1×1 卷积投影到多个与每个任务对应的任务分割中，这可以表示为 $\{\mathbf{X}^t = f_{t,1 \times 1}(\mathbf{X}), t \in [1, \dots, T]\}$ ，其中 $\mathbf{X}^t \in \mathbb{R}^{C \times H \times W}$ 。然后，任务特征被送到三个路径中，即任务共享的通用路径 $f_g(\cdot)$ 、任务共享低秩专家路径 $f_{lre}(\cdot)$ （具有任务特定路由网络 $f_{sr}^t(\cdot)$ ）和任务特定低秩专家路径 $f_{se}(\cdot)$ 。最终的任务特定特征 $\mathbf{S}^t$ 通过以下公式获得

$$\mathbf{S}^t = f_g(\mathbf{X}^t) + f_{sr}^t(f_{lre}(\mathbf{X}^t)) + f_{se}^t(\mathbf{X}^t). \quad (2)$$

接下来，我们介绍 MLoRE 模型中关于这三个路径的网络细节。

任务共享通用路径包含一个简单的 3×3 卷积层，其权重矩阵为 $\mathbf{W}_g \in \mathbb{R}^{3 \times 3 \times C \times C}$ 和偏置矩阵 $\mathbf{b}_g \in \mathbb{R}^C$ 。由于所有任务特征都会经过此通用卷积，因此它会同时通过不同任务的梯度进行优化，这有助于提取所有任务之间的共性特征。在训练过程中，我们停止对该路径

的梯度进行进一步反向传播。梯度通过其他两个路径进行反向传播。我们发现这样一个简单的操作可以更好地缓解优化过程中的梯度冲突。实验结果在 Sec. 4.2 显示, 简单的任务共享通用路径可以在所有任务上带来性能提升, 证明了从全局角度明确建立跨任务关系的想法的有效性。

任务共享低秩专家路径我们借鉴了 LoRA [21] 的思想, 采用低秩卷积, 这是一种低秩格式的普通卷积。每个任务共享专家网络具有类似的结构, 包括一个 3×3 卷积和一个 1×1 卷积。所有任务共享专家网络的权重和偏置可以表示为 $\{\mathbf{W}_{lreb}^n, \mathbf{b}_{lreb}^n, \mathbf{W}_{lrea}^n, \mathbf{b}_{lrea}^n | n \in [1, \dots, N]\}$, 其中 $\mathbf{W}_{lreb}^n \in \mathbb{R}^{3 \times 3 \times C \times r_n}$, $\mathbf{b}_{lreb}^n \in \mathbb{R}^{r_n}$, $\mathbf{W}_{lrea}^n \in \mathbb{R}^{1 \times 1 \times r_n \times C}$, 且 $\mathbf{b}_{lrea}^n \in \mathbb{R}^C$ ($r_n \ll C$)。 r_n 表示第 n 个专家网络的秩。在我们的方法中, 不同专家网络的 r_n 值不同, 旨在提高参数和特征的多样性。对于每个任务, 任务特定路由网络 $f_{sr}^t(\cdot)$ 学习这些专家的门控值并根据门控值激活 top- k 专家。所有激活的专家的输出特征被加总后, 送入 BatchNorm 层生成任务特定特征。BatchNorm 层包含四个参数, 包括累积的通道均值 $\mu \in \mathbb{R}^C$ 、累积的通道标准差 $\sigma \in \mathbb{R}^C$ 、缩放因子 $\gamma \in \mathbb{R}^C$ 和偏置 $\beta \in \mathbb{R}^C$ 。

特定任务低秩专家路径包含 T 个特定的专家网络, 每个网络处理一个任务特征。对于每个特定专家网络, 我们使用与任务共享专家路径类似的结构, 包括一个 3×3 卷积, 其权重矩阵为 $\mathbf{W}_{seb}^t \in \mathbb{R}^{3 \times 3 \times C \times R}$ 和偏置矩阵 $\mathbf{b}_{seb}^t \in \mathbb{R}^R$, 接着是一个 1×1 卷积, 其权重矩阵为 $\mathbf{W}_{sea}^t \in \mathbb{R}^{1 \times 1 \times R \times C}$ 和偏置矩阵 $\mathbf{b}_{sea}^t \in \mathbb{R}^C$ 。 R 表示秩数 ($R \ll C$)。任务特定专家路径可以增强任务特定特征的特异性, 这一点将在实验中验证。

路由网络如 Fig. 2 所示, 为了从任务共享低秩专家路径生成任务特定特征, 我们学习任务特定路由网络, 为每个专家生成门控值, 并将其作为不同专家特征输出的线性组合的权重。每个任务的路由网络通常是简单的线性层, 后跟平均池化层和预测层。具体来说, 任务 t 的路由网络 $f_{sr}^t(\cdot)$ 设计如下。我们的路由网络以任务特定特征 $\mathbf{X}^t \in \mathbb{R}^{C \times H \times W}$ 作为输入, 并将其送入两个连续的 1×1 卷积, 将通道维度从 C 映射到 $C/4$, 然后是一个全局池化层。输出是一个全局特征向量 $\mathbf{X}_f \in \mathbb{R}^{\frac{C}{4}}$ 。

此外, 受之前工作的启发 [19, 20], 我们引入了另一个并行的基于位置的分支。类似地, 它由两个线性层

组成。第一个线性层沿空间维度缩小特征, 将形状从 $\mathbb{R}^{C \times HW}$ 映射到 $\mathbb{R}^{C \times 1}$, 然后通过第二个线性层转换到 $\mathbb{R}^{\frac{C}{4}}$ 。这两个分支的输出特征向量沿最终维度拼接在一起, 然后送入最终预测层, 后跟 Softmax 函数以生成每个专家的门控值 g_t 。

推理时的重参数化我们通过移除所有激活函数, 在 MLoRE 模块中引入了线性化, 这使得在推理时可以将所有路径的参数重新参数化为每个任务的简单 3×3 卷积。我们首先对任务共享低秩专家路径进行参数化, 然后对所有路径的参数进行参数化。根据 [12] 的研究, 任务共享专家路径中的权重和偏置矩阵可以合并并表示为:

$$\mathbf{W}_{lre}^t = \mathfrak{B}\left(\frac{\gamma}{\sigma}\right) \sum_{k \in \mathbb{K}_t} \mathbf{g}_k^t \mathbf{W}_{lreb}^k \mathbf{W}_{lrea}^k, \quad (3)$$

$$\mathbf{b}_{lre}^t = \frac{\gamma}{\sigma} \left(\sum_{k \in \mathbb{K}_t} \mathbf{g}_k^t (\mathbf{b}_{lreb}^k \mathbf{W}_{lrea}^k + \mathbf{b}_{lrea}^k) - \mu \right) + \beta, \quad (4)$$

其中, $\mathfrak{B}$ 表示广播操作, $\mathbb{K}_t$ 表示由路由网络为任务 t 选择的激活专家的索引集。 $\mathbf{g}_k^t$ 是路由网络预测的第 k 个门控值。在推理阶段, 这三个路径的权重矩阵和偏置矩阵可以重新参数化为:

$$\mathbf{W}_r^t = \mathbf{W}_g + \mathbf{W}_{sr}^t + \mathbf{W}_{seb}^t \mathbf{W}_{sea}^t, \quad (5)$$

$$\mathbf{b}_r^t = \mathbf{b}_g + \mathbf{b}_{sr}^t + \mathbf{b}_{seb}^t \mathbf{W}_{sea}^t + \mathbf{b}_{sea}^t. \quad (6)$$

$\mathbf{W}_r^t$ 和 $\mathbf{b}_r^t$ 是重新参数化卷积的权重和偏置。因此, Eqn. (2) 可以重新表述为:

$$\mathbf{S}^t = \mathbf{X}^t \circledast \mathbf{W}_r^t + \mathfrak{B}(\mathbf{b}_r^t), \quad (7)$$

其中, $\circledast$ 表示卷积操作, $\mathbf{b}_r^t$ 通过广播机制与 $\mathbf{X}^t$ 具有相同的形状。

4. Experiments

4.1. 实验设置

数据集。为了证明我们方法的有效性, 我们在两个流行的多任务数据集上评估了我们方法的性能, 这两个数据集是 PASCAL-Context [7] 和 NYUD-v2 [39]。PASCAL-Context [7] 包含了多个任务的高质量标注, 包括语义分割、人体解析、显著性检测、表面法线和物体边界检测。该数据集中有 4,998 张训练图像和 5,105 张测试图像。NYUDv2 [39] 也提供了高质量的多任务

表 2. 在 PASCAL-Context 数据集上 MLoRE 不同组件的消融研究。每一行在上行的基础上增加了一个额外的设置。MoE: 标准的专家混合结构; LoRE: 任务共享低秩专家路径; GC: 任务共享通用卷积路径; SPE: 任务特定专家路径。↑ 表示越高越好。↓ 表示越低越好。

设置	Semseg		Parsing		Sal.		Normal		Bound. MTL		FLOPs #Param	
	mIoU ↑	mIoU ↑	mIoU ↑	mIoU ↑	maxF ↑	mErr ↓	odsF ↑	Δ_m ↑	odsF ↑	Δ_m ↑	(G)	(M)
Baseline	77.38	65.15	85.08	13.79	69.87	-3.41					391	115
+ MoE	78.56	66.78	85.18	13.57	73.91	-1.20					1834	676
Baseline												
+ LoRE	78.38	66.21	85.15	13.71	73.53	-1.71					568	213
+ GC	79.25	67.43	85.20	13.70	74.38	-0.88					568	243
+ SPE	79.26	67.82	85.31	13.65	74.69	-0.58					568	259

注释, 包括语义分割、单目深度估计、表面法线和物体边界检测。该数据集包含 795 张训练图像和 654 张测试图像。

评估指标。我们介绍了上述任务的评估指标。遵循以往的多任务工作 [48,49], 我们使用平均交并比 (mIoU) 来评估语义分割和人像解析的性能。根均方误差 (RMSE) 用于评估单目深度估计的准确性。显著性检测使用最大 F-measure (maxF)。表面法线和物体边界检测分别采用平均误差 (mErr) 和最优数据集尺度 F-measure (odsF) 作为评估指标。总的来说, 我们按照 [34] 的方法评估了所有任务的 MTL 增益 Δ_m 。

训练设置。我们使用 ViT-large [13] 作为主干网络。解码器的通道数设置为 384。对于消融研究, 主干网络设置为 ViT-base 网络。按照之前的工作 [49], 我们在这两个数据集上用批量大小为 4 训练了 40,000 次迭代的 MTL 网络。不同任务的优化器和损失函数遵循之前的工作 [49]。

4.2. Ablation Study

在本小节中, 我们进行广泛的实验来展示不同组件的有效性, 并找到不同超参数的最佳设置。所有的消融实验都是基于 ViT 主干网络进行的, 除非另有说明。基线建立在具有 12 层的 ViT-base 主干网络上, 利用来自第 3 层、第 6 层、第 9 层和第 12 层的 Backbone 特征作为多尺度特征, 每个特征后面都跟着一个线性层, 将通道维度投影到每个任务的输出通道。

不同组件的有效性。我们首先进行实验, 以验证 MLoRE 模块中不同组件的有效性。Tab. 2 显示了定量结果。我




图 3. 关于专家数量 N 和激活专家数量 K 的消融实验。在右图中, 我们还展示了随着专家数量增加, MLoRE 模块参数的变化。

们首先检查带有标准 MoE 的 Baseline 的性能, 以及它们模型的参数大小和 FLOPs。标准 MoE (15 个专家网络) 中的专家网络与我们的相似, 每个网络都由一个 3×3 卷积和一个 1×1 卷积组成, 中间使用 ReLU 激活函数。当将 MoE 添加到 Baseline 中时, 我们观察到 MTL 增益有所提高, 但参数和 FLOPs 也分别增加了大约 5 倍和 4 倍, 这对整个网络来说是一个沉重的负担。当将低秩专家网络 (LoRE) 添加到 Baseline 时, 性能同样得到了提升, 但参数和 FLOPs 仅为基于 MoE 模型的 $1/3$ 。当将低秩特性应用于专家网络时, 参数大小减少了数倍。进一步地, 通过移除所有激活函数, 在专家网络中引入线性化, 可以通过将所有专家重参数化为单个卷积来节省计算资源。

此外, 我们还强调在 MoE 中明确构建全局任务关联的重要性, 并引入任务共享通用路径来实现这一目标。可以看到, 向 LoRE 添加任务共享通用路径可以进一步提升性能, 并在大多数指标上超越带有 MoE 的 Baseline, 这证明了建模所有任务之间全局关系的有效性。此外, 为每个任务添加任务特定的低秩专家也提升了性能, 证明了专门化的专家网络可以增强任务特定特征的区分性。在本文中, 我们经验性地将任务特定低秩专家的秩设为 64。

任务共享低秩专家的数量和 top- k 选择。我们对 MLoRE 模块中低秩专家的数量和任务特定路由网络选择的 top- k 专家进行了消融实验。我们首先固定一个参数, 消融另一个参数, 以研究它们对多任务性能的影响。如 Fig. 3 所示, 当增加专家数量时, 模型的 MTL 增益显著提升, 并在专家数量为 15 时实现了最佳性能。进一步增加专家数量时, 我们没有观察到明显的性能提升。此外, 当将专家数量固定为 15 时, 我们对激活专家的比例进行了消融实验。我们观察到, 在我们的实

表 3. 在 PASCAL-Context 数据集上, MLoRE 任务共享低秩专家路径中的秩设置消融实验。

Min/Max Rank	Semseg Parsing Saliency Normal Boundary					MTL $\Delta_m \uparrow$
	mIoU $\uparrow$	mIoU $\uparrow$	maxF $\uparrow$	mErr $\downarrow$	odsF $\uparrow$	
16/16	78.84	68.01	85.32	13.69	74.39	-0.77
16/128	79.26	67.82	85.30	13.65	74.69	-0.58
128/128	78.79	66.98	85.35	13.67	74.29	-1.07

验中, 为每个任务激活 60% 的专家是最佳选择。当选择所有专家网络时, 性能大幅下降, 这反映了稀疏性对于特征区分的重要性。

秩数设置。专家网络利用的是带有 640 个输出通道的标准 3×3 卷积的低秩格式。不同专家网络的秩 r 也起着重要作用。我们研究了不同的设置, 包括 1) 所有专家的秩数为 16, 2) 所有专家的秩数为 128, 3) 专家秩数从 16 增加到 128, 每次增加 8 个单位。如表 Tab. 3 所示, 可以看到为专家网络选择不同的秩数可以实现最佳的 MTL 增益。我们分析了不同秩数的专家网络, 它们可以带来比相同秩数更多的特征多样性, 这对组合任务特定的特征更有用, 并将其作为我们的设置。

关系可视化。任务与低秩专家之间的关系如 Fig. 4(a) 所示。我们统计了最后阶段第二个 MLoRE 模块中的关系, 并计算了不同任务在整个数据集上选择的每个专家的激活比例。可以看到, 不同秩数的专家倾向于学习不同的任务子集。具体而言, 秩较低的专家倾向于为 3-4 个相关任务学习共享知识, 而秩较高的专家则专注于 1-2 个任务。此外, 我们还展示了在未添加任务共享通用路径时, MLoRE 模块中不同任务激活不同专家的比例, 如 Fig. 4(b) 所示。可以看到, 在完全动态的方式下, 这些专家很少或从未被所有任务在同一个样本中激活。这证明了在直接使用 MoE 解码器时, 几乎没有专家可以学习所有任务的全局关系。这种现象强烈支持了任务共享通用路径的必要性, 用于显式建模全局任务关系。

任务特定的路由网络。路由网络对于生成任务特定的门控机制至关重要, 这决定了如何激活专家并组合他们的特征。我们对路由网络的几个设置进行了消融实验, 结果如表 4 所示。在基础路由网络中添加位置感知分支可以将 MTL 增益提高 +0.17。位置感知分支可以获得更多的上下文信息, 这对路由网络有益。此外, 当将路由的输入从可学习参数更换为样本特征时, MTL 增

表 4. 路由网络设置的消融实验。**basic:** 基础路由网络。**pos.:** 位置感知路由网络。**w/o sample-dep:** 输入为可学习参数的设置。

Router Variant	Semseg Parsing Saliency Normal Boundary					MTL $\Delta_m \uparrow$
	mIoU $\uparrow$	mIoU $\uparrow$	maxF $\uparrow$	mErr $\downarrow$	odsF $\uparrow$	
basic	79.15	67.40	85.21	13.58	74.34	-0.75
basic+pos.	79.26	67.82	85.31	13.65	74.69	-0.58
only pos.	79.10	67.76	85.11	13.71	74.51	-0.82
basic	79.15	67.40	85.21	13.58	74.34	-0.75
w/o sample-dep	78.86	67.38	85.41	13.65	74.25	-0.91

益增加了 +0.16, 这表明样本的动态信息对门控机制至关重要。

4.3. 与其他方法的比较

与之前最先进的 (SOTA) 方法的定量比较如表 Tab. 5 和 Tab. 6 所示。可以看出, 我们的方法在 PASCAL-Context 和 NYUDv2 数据集上的所有指标上明显优于之前的方法。尤其是在 PASCAL-Context 数据集上, 语义分割、人体解析和边界检测的表现分别比之前最好的方法提升了 +0.52 mIoU、+1.10 mIoU 和 +1.92 odsF。

之前的方法, 如 M³ViT [14]、Mod-Squad [10] 和 TaskExpert [50] 都在他们的网络中使用了 MoE 技术。然而, 我们的方法表现优于它们, 这证明了 MLoRE 模块的有效性。相比于专注于解码器的方法 TaskExpert, 我们的语义分割、人体解析和对象边界检测性能分别显著提高了 +0.77 mIoU、+1.10 mIoU 和 +2.12 odsF, 同时使用了更少的参数和 FLOPs。

我们还在图 Fig. 5 中直观展示了与其他方法的对比。我们的方法在语义分割、人体解析和对象边界检测任务上的可视化结果优于之前的 SOTA 方法。更多的可视化比较见补充材料。

4.4. 高效的多任务学习模型

我们还将我们的 MLoRE 模块应用于 ViT-small 骨干网络, 检查高效模型的性能。具体来说, 解码器的通道数从 384 减少到 192。如表 Tab. 7 所示, 我们的方法使用约 TaskExpert 35% 的 GFLOPs, 能够实现极具竞争力的结果。特别是在语义分割和目标边界任务上, 分别提升了 0.6% mIoU 和 1.01% odsF, 而其他任务的指标与 TaskExpert 接近。此外, 参数数量比




图 4. (a) 任务与低秩专家之间的关系。(b) MLoRE 模块中不同任务激活专家的比例（未使用任务共享通用路径）。我们可以看到，在没有任务共享通用路径的情况下，只有少数专家能够被所有五个任务激活。横坐标表示不同专家的秩。

表 5. PASCAL-Context 数据集上不同方法的定量比较。* 表示基于 [50] 中 ViT-large 骨干网络复现的方法性能。

Method	Publication	Backbone	Semseg mIoU $\uparrow$	Parsing mIoU $\uparrow$	Saliency maxF $\uparrow$	Normal mErr $\downarrow$	Boundary odsF $\uparrow$	FLOPs (G)	#Param (M)
PAD-Net [46]	CVPR'18	HRNet18	53.60	59.60	65.80	15.30	72.50	124	81
MTI-Net [45]	ECCV'20	HRNet18	61.70	60.18	84.78	14.23	70.80	161	128
ATRC [4]	ICCV'21	HRNet18	67.67	62.93	82.29	14.24	72.42	216	96
PAD-Net* [46]	CVPR'18	ViT-large	78.01	67.12	79.21	14.37	72.60	773	330
MTI-Net* [45]	ECCV'20	ViT-large	78.31	67.40	84.75	14.67	73.00	774	851
ATRC* [4]	ICCV'21	ViT-large	77.11	66.84	81.20	14.23	72.10	871	340
InvPT [48]	ECCV'22	ViT-large	79.03	67.61	84.81	14.15	73.00	669	423
TaskPrompter [49]	ICLR'23	ViT-large	80.89	68.89	84.83	13.72	73.50	497	401
TaskExpert [50]	ICCV'23	ViT-large	80.64	69.42	84.87	13.56	73.30	622	420
Ours	-	ViT-large	81.41	70.52	84.90	13.51	75.42	571	407

表 6. 不同方法在 NYUD-v2 数据集上的定量比较。我们的方法在所有四项任务上表现最佳。

Method	Backbone	Semseg mIoU $\uparrow$	Depth RMSE $\downarrow$	Normal mErr $\downarrow$	Boundary odsF $\uparrow$
PAD-Net [46]	HRNet18	36.61	0.6246	20.88	76.38
MTI-Net [45]	HRNet48	45.97	0.5365	20.27	77.86
ATRC [4]	HRNet48	46.33	0.5363	20.18	77.94
InvPT [48]	ViT-large	53.56	0.5183	19.04	78.10
TaskPrompter [49]	ViT-large	55.30	0.5152	18.47	78.20
TaskExpert [50]	ViT-large	55.35	0.5157	18.54	78.40
Ours	ViT-large	55.96	0.5076	18.33	78.43

TaskExpert 少了 11M。

4.5. 结论

我们提出了一种新颖的以解码器为中心的多任务学习方法，名为 MLoRE。我们深入探讨了标准的专家混合 (MoE) 技术，并从两个方面对其进行了改进以适应密集的多任务学习。首先，为了解决 MoE 中忽视的全局关系建模问题，我们在 MoE 中添加了一个简单的通用卷积路径，使不同的任务特征可以共享这一路径。




图 5. 不同方法的定性比较，包括 InvPT [48]、TaskPrompter [49] 和我们的方法。放大查看效果更佳。可以看到，由于提出的 MLoRE 模块，我们的方法在五个任务上都取得了比其他方法更好的视觉效果。

此外，我们将标准卷积的低秩格式应用于不同的专家网络，以减少 MoE 在增加专家数量时的高计算成本和大量参数。实验结果表明，提出的方法在所有指标上明显优于现有的最先进方法。

致谢本研究得到国家自然科学基金（编号：62276145）、

表 7. 基于 MoE 的高效模型在 PASCAL-Context 数据集上的定量比较。

Method	Semseg Parsing		Sal.	Nor.	Bound.	FLOPs (G)	#Param (M)
	mIoU $\uparrow$	mIoU $\uparrow$	maxF $\uparrow$	mErr $\downarrow$	odsF $\uparrow$		
M ³ ViT	72.80	62.10	66.30	14.50	71.70	420	42
Mod-Squad	74.10	62.70	66.90	13.70	72.00	420	52
TaskExpert	75.04	62.68	84.68	14.22	68.80	204	55
ours	75.64	62.65	84.70	14.43	69.81	72	44

中央高校基本科研业务费（南开大学，070-63223049）、中国科协青年英才资助计划（编号：YESS20210377）支持。计算由南开大学超级计算中心提供支持。

参考文献

- [1] Armen Aghajanyan, Luke Zettlemoyer, and Sonal Gupta. Intrinsic dimensionality explains the effectiveness of language model fine-tuning. *arXiv preprint arXiv:2012.13255*, 2020. 3
- [2] Shariq Farooq Bhat, Ibraheem Alhashim, and Peter Wonka. Adabins: Depth estimation using adaptive bins. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 4009–4018, 2021. 1
- [3] David Bruggemann, Menelaos Kanakis, Stamatios Georgoulis, and Luc Van Gool. Automated search for resource-efficient branched multi-task networks. *arXiv preprint arXiv:2008.10292*, 2020. 3
- [4] David Bruggemann, Menelaos Kanakis, Anton Obukhov, Stamatios Georgoulis, and Luc Van Gool. Exploring relational context for multi-task dense prediction. In *Int. Conf. Comput. Vis.*, pages 15869–15878, 2021. 1, 3, 8
- [5] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE Trans. Pattern Anal. Mach. Intell.*, 40(4):834–848, 2017. 1
- [6] Tianlong Chen, Xuxi Chen, Xianzhi Du, Abdullah Rashwan, Fan Yang, Huizhong Chen, Zhangyang Wang, and Yeqing Li. Adamv-moe: Adaptive multi-task vision mixture-of-experts. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 17346–17357, 2023. 2, 3
- [7] Xianjie Chen, Roozbeh Mottaghi, Xiaobai Liu, Sanja Fidler, Raquel Urtasun, and Alan Yuille. Detect what you can: Detecting and representing objects using holistic models and body parts. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1971–1978, 2014. 5
- [8] Zhao Chen, Vijay Badrinarayanan, Chen-Yu Lee, and Andrew Rabinovich. Gradnorm: Gradient normalization for adaptive loss balancing in deep multitask networks. In *International conference on machine learning*, pages 794–803. PMLR, 2018. 3
- [9] Zhao Chen, Jiquan Ngiam, Yanping Huang, Thang Luong, Henrik Kretzschmar, Yuning Chai, and Dragomir Anguelov. Just pick a sign: Optimizing deep multi-task models with gradient sign dropout. *Advances in Neural Information Processing Systems*, 33:2039–2050, 2020. 3
- [10] Zitian Chen, Yikang Shen, Mingyu Ding, Zhenfang Chen, Hengshuang Zhao, Erik G Learned-Miller, and Chuang Gan. Mod-squad: Designing mixtures of experts as modular multi-task learners. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 11828–11837, 2023. 2, 3, 4, 7
- [11] Aidan Clark, Diego De Las Casas, Aurelia Guy, Arthur Mensch, Michela Paganini, Jordan Hoffmann, Bogdan Damoc, Blake Hechtman, Trevor Cai, Sebastian Borgeaud, et al. Unified scaling laws for routed language models. In *Int. Conf. Mach. Learn.*, pages 4057–4086. PMLR, 2022. 2
- [12] Xiaohan Ding, Xiangyu Zhang, Jungong Han, and Guiguang Ding. Diverse branch block: Building a convolution as an inception-like unit. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 10886–10895, 2021. 5
- [13] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *Int. Conf. Learn. Represent.*, 2020. 6
- [14] Zhiwen Fan, Rishov Sarkar, Ziyu Jiang, Tianlong Chen, Kai Zou, Yu Cheng, Cong Hao, Zhangyang Wang, et al. M³vit: Mixture-of-experts vision transformer for efficient multi-task learning with model-accelerator co-design. In *Adv. Neural Inform. Process. Syst.*, volume 35, pages 28441–28457, 2022. 2, 3, 4, 7
- [15] William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *The Journal*

- of *Machine Learning Research*, 23(1):5232–5270, 2022. 2
- [16] Yuan Gao, Jiayi Ma, Mingbo Zhao, Wei Liu, and Alan L Yuille. Nddr-cnn: Layerwise feature fusing in multi-task cnns by neural discriminative dimensionality reduction. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 3205–3214, 2019. 1, 3
- [17] Michelle Guo, Albert Haque, De-An Huang, Serena Yeung, and Li Fei-Fei. Dynamic task prioritization for multitask learning. In *Proceedings of the European conference on computer vision (ECCV)*, pages 270–287, 2018. 3
- [18] Pengsheng Guo, Chen-Yu Lee, and Daniel Ulbricht. Learning to branch for multi-task learning. In *Int. Conf. Mach. Learn.*, pages 3854–3863. PMLR, 2020. 3
- [19] Qibin Hou, Li Zhang, Ming-Ming Cheng, and Jiashi Feng. Strip pooling: Rethinking spatial pooling for scene parsing. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 4003–4012, 2020. 5
- [20] Qibin Hou, Daquan Zhou, and Jiashi Feng. Coordinate attention for efficient mobile network design. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 13713–13722, 2021. 5
- [21] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021. 3, 5
- [22] Yerlan Idelbayev and Miguel A Carreira-Perpinán. Low-rank compression of neural nets: Learning the rank of each layer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8049–8059, 2020. 3
- [23] Keishi Ishihara, Anssi Kanervisto, Jun Miura, and Ville Hautamaki. Multi-task learning with attention for end-to-end autonomous driving. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 2902–2911, 2021. 1
- [24] Robert A Jacobs and Michael I Jordan. Learning piecewise control strategies in a modular neural network architecture. *IEEE Transactions on Systems, Man, and Cybernetics*, 23(2):337–345, 1993. 3
- [25] Robert A Jacobs, Michael I Jordan, Steven J Nowlan, and Geoffrey E Hinton. Adaptive mixtures of local experts. *Neural Comput.*, 3(1):79–87, 1991. 3
- [26] Shibo Jie and Zhi-Hong Deng. Fact: Factor-tuning for lightweight adaptation on vision transformer. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 1060–1068, 2023. 3
- [27] Alex Kendall, Yarin Gal, and Roberto Cipolla. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7482–7491, 2018. 3
- [28] Zhihao Li, Toshiyuki Motoyoshi, Kazuma Sasaki, Tetsuya Ogata, and Shigeki Sugano. Rethinking self-driving: Multi-task knowledge for better generalization and accident explanation ability. *arXiv preprint arXiv:1809.11100*, 2018. 1
- [29] Guosheng Lin, Anton Milan, Chunhua Shen, and Ian Reid. Refinenet: Multi-path refinement networks for high-resolution semantic segmentation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1925–1934, 2017. 1
- [30] Shikun Liu, Edward Johns, and Andrew J Davison. End-to-end multi-task learning with attention. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1871–1880, 2019. 3
- [31] Yen-Cheng Liu, Chih-Yao Ma, Junjiao Tian, Zijian He, and Zsolt Kira. Polyhistor: Parameter-efficient multi-task adaptation for dense vision tasks. *Advances in Neural Information Processing Systems*, 35:36889–36901, 2022. 3
- [32] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 3431–3440, 2015. 1
- [33] Yongxi Lu, Abhishek Kumar, Shuangfei Zhai, Yu Cheng, Tara Javidi, and Rogerio Feris. Fully-adaptive feature sharing in multi-task networks with applications in person attribute classification. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5334–5343, 2017. 1, 3
- [34] Kevis-Kokitsi Maninis, Ilija Radosavovic, and Iasonas Kokkinos. Attentive single-tasking of multiple tasks. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1851–1860, 2019. 6
- [35] Ishan Misra, Abhinav Shrivastava, Abhinav Gupta, and Martial Hebert. Cross-stitch networks for multi-

- task learning. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 3994–4003, 2016. 1, 3
- [36] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 3
- [37] René Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Int. Conf. Comput. Vis.*, pages 12179–12188, 2021. 1
- [38] Sebastian Ruder, Joachim Bingel, Isabelle Augenstein, and Anders Søgaard. Latent multi-task architecture learning. In *AAAI Conf. Artif. Intell.*, volume 33, pages 4822–4829, 2019. 3
- [39] Nathan Silberman, Derek Hoiem, Pushmeet Kohli, and Rob Fergus. Indoor segmentation and support inference from rgbd images. In *Eur. Conf. Comput. Vis.*, pages 746–760. Springer, 2012. 5
- [40] Chi Su, Fan Yang, Shiliang Zhang, Qi Tian, Larry S Davis, and Wen Gao. Multi-task learning with low rank attribute embedding for person re-identification. In *Proceedings of the IEEE international conference on computer vision*, pages 3739–3747, 2015. 3
- [41] Yi-Lin Sung, Jaemin Cho, and Mohit Bansal. Vl-adapt: Parameter-efficient transfer learning for vision-and-language tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5227–5237, 2022. 3
- [42] Madeleine Udell, Corinne Horn, Reza Zadeh, Stephen Boyd, et al. Generalized low rank models. *Foundations and Trends® in Machine Learning*, 9(1):1–118, 2016. 3
- [43] Simon Vandenhende, Stamatios Georgoulis, Bert De Brabandere, and Luc Van Gool. Branched multi-task networks: deciding what layers to share. In *Brit. Mach. Vis. Conf.*, 2019. 3
- [44] Simon Vandenhende, Stamatios Georgoulis, Wouter Van Gansbeke, Marc Proesmans, Dengxin Dai, and Luc Van Gool. Multi-task learning for dense prediction tasks: A survey. *IEEE Trans. Pattern Anal. Mach. Intell.*, 44(7):3614–3633, 2021. 3
- [45] Simon Vandenhende, Stamatios Georgoulis, and Luc Van Gool. Mti-net: Multi-scale task interaction networks for multi-task learning. In *Eur. Conf. Comput. Vis.*, pages 527–543. Springer, 2020. 1, 3, 8
- [46] Dan Xu, Wanli Ouyang, Xiaogang Wang, and Nicu Sebe. Pad-net: Multi-tasks guided prediction-and-distillation network for simultaneous depth estimation and scene parsing. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 675–684, 2018. 1, 3, 8
- [47] Yongxin Yang and Timothy M Hospedales. Trace norm regularised deep multi-task learning. *arXiv preprint arXiv:1606.04038*, 2016. 3
- [48] Hanrong Ye and Dan Xu. Inverted pyramid multi-task transformer for dense scene understanding. In *Eur. Conf. Comput. Vis.*, pages 514–530. Springer, 2022. 1, 2, 3, 6, 8
- [49] Hanrong Ye and Dan Xu. Taskprompter: Spatial-channel multi-task prompting for dense scene understanding. In *Int. Conf. Learn. Represent.*, 2022. 2, 3, 6, 8
- [50] Hanrong Ye and Dan Xu. Taskexpert: Dynamically assembling multi-task representations with memorial mixture-of-experts. In *Int. Conf. Comput. Vis.*, 2023. 2, 3, 7, 8
- [51] Changqian Yu, Jingbo Wang, Chao Peng, Changxin Gao, Gang Yu, and Nong Sang. Bisenet: Bilateral segmentation network for real-time semantic segmentation. In *Eur. Conf. Comput. Vis.*, pages 325–341, 2018. 1
- [52] Fisher Yu, Haofeng Chen, Xin Wang, Wenqi Xian, Yingying Chen, Fangchen Liu, Vashisht Madhavan, and Trevor Darrell. Bdd100k: A diverse driving dataset for heterogeneous multitask learning. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 2636–2645, 2020. 1
- [53] Zhenyu Zhang, Zhen Cui, Chunyan Xu, Zequn Jie, Xiang Li, and Jian Yang. Joint task-recursive learning for semantic segmentation and depth estimation. In *Eur. Conf. Comput. Vis.*, pages 235–251, 2018. 3
- [54] Zhenyu Zhang, Zhen Cui, Chunyan Xu, Yan Yan, Nicu Sebe, and Jian Yang. Pattern-affinitive propagation across depth, surface normal and semantic segmentation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 4106–4115, 2019. 3
- [55] Xiangyun Zhao, Haoxiang Li, Xiaohui Shen, Xiaodan Liang, and Ying Wu. A modulation module for multi-task learning with applications in image retrieval. In

Proceedings of the European Conference on Computer Vision (ECCV), pages 401–416, 2018. 3

- [56] Ling Zhou, Zhen Cui, Chunyan Xu, Zhenyu Zhang, Chaoqun Wang, Tong Zhang, and Jian Yang. Pattern-structure diffusion for multi-task learning. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 4514–4523, 2020. 3